Simulador de mundos habitables

Predicción de supervivencia con modelos sustitutos y explicabilidad verificable

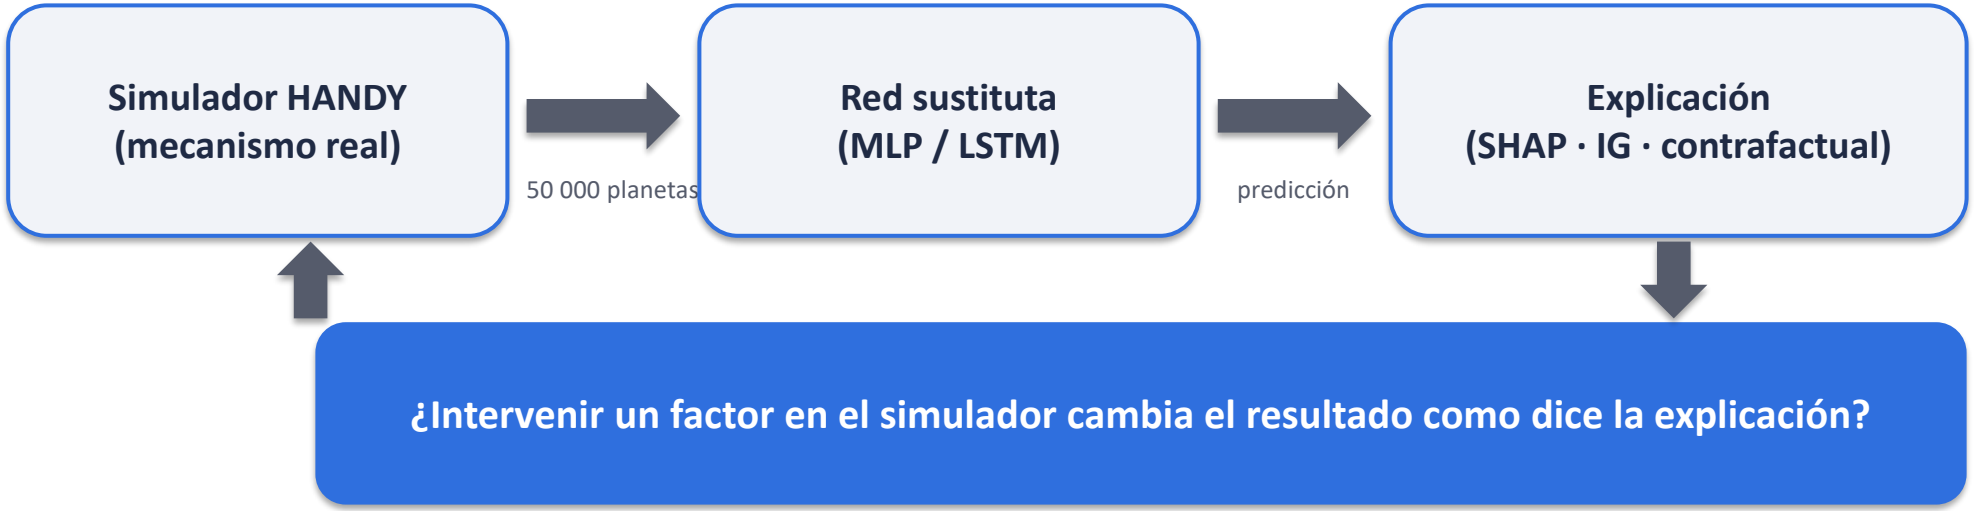
¿Podemos creerle a una explicación?

Gabriel Bran · David Domínguez · Jonathan Díaz

Deep Learning · Sección 10 · Universidad del Valle de Guatemala · 2 de noviembre de 2026

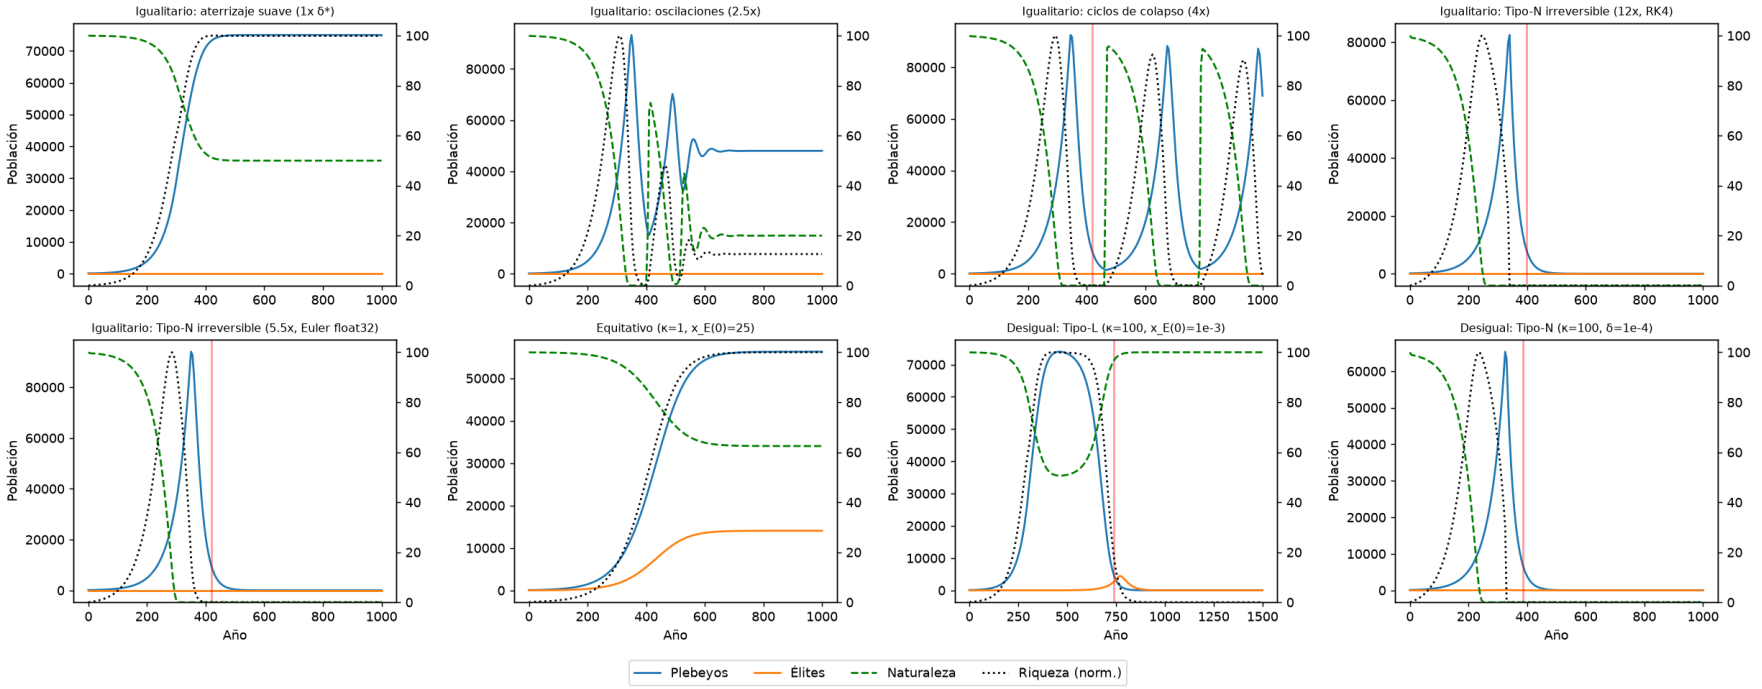
El problema: sustitutos que no sabemos explicar

- Los simuladores científicos son caros: se usan redes como modelos sustitutos (surrogates).
- Las explicaciones (SHAP, IG, contrafactuales) casi nunca tienen una verdad de referencia.
- S15: una explicación post-hoc es un «modelo del modelo»: puede ser útil sin ser fiel.
- Aquí sí hay verdad: el simulador es el mecanismo real, así que podemos intervenir y medir la fidelidad.



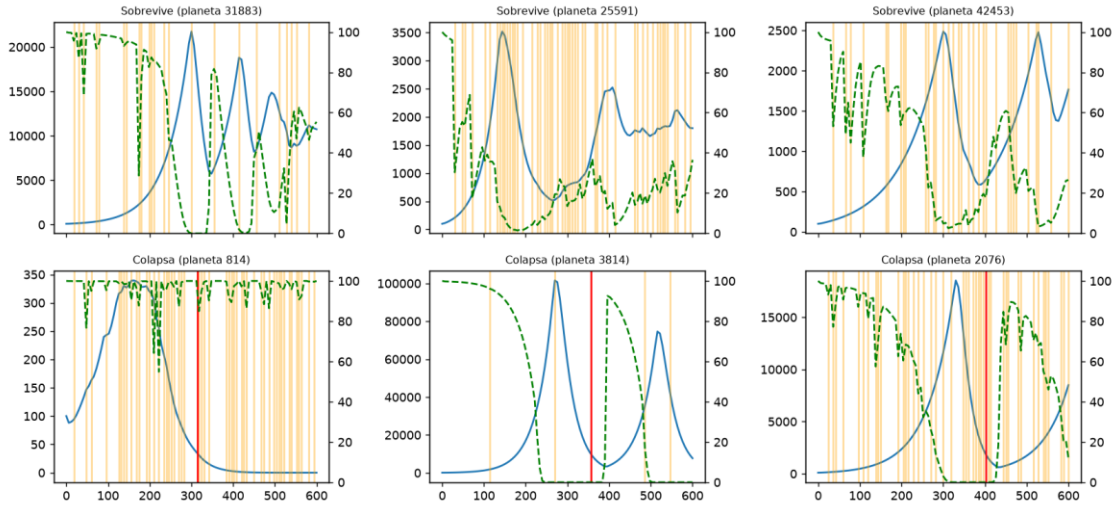
El simulador: HANDY extendido

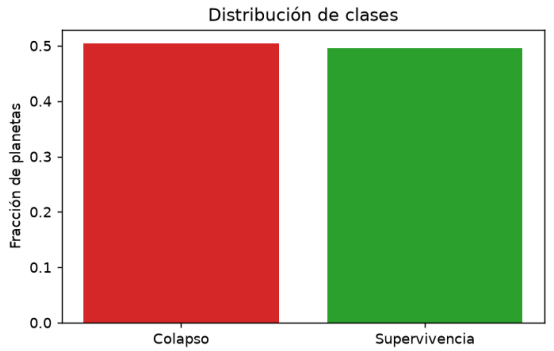
- HANDY (Motesharrei et al., 2014): plebeyos x_C, élites x_E, naturaleza y, riqueza w. Ecuaciones (3)–(6) verificadas contra el paper (un error nuestro corregido).
- Valores del paper: β = 0.03, γ = 0.01, s = $5 \cdot 10^{-4}$, ρ = $5 \cdot 10^{-3}$, λ = 100, α_m = 0.01, α_M = 0.07; equilibrio δ* ≈ $6.67 \cdot 10^{-6}$. Aquí varían δ, κ, s, β y γ.
- Integración RK4, dt = 1 año, 600 años, 101 puntos guardados (cada 6 años), vectorizada.
- Extensiones: temperatura (γ·e^−(T/3)², α_m·(1 + 0.15|T|)); agua (λ·clip(oferta/demanda, 0.05, 1)); eventos Poisson que destruyen una fracción sev·U de naturaleza y riqueza.
- 11 factores, 4 accionables (δ, κ, s, eficiencia hídrica). Colapso: población < máx(10 % del pico, 20 % de la inicial) antes del año 600.

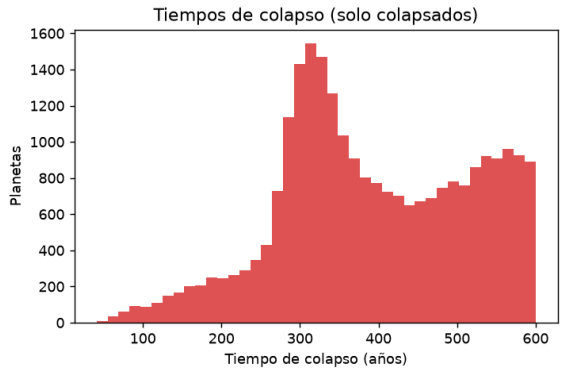


Datos: 50 000 planetas y una verdad de referencia

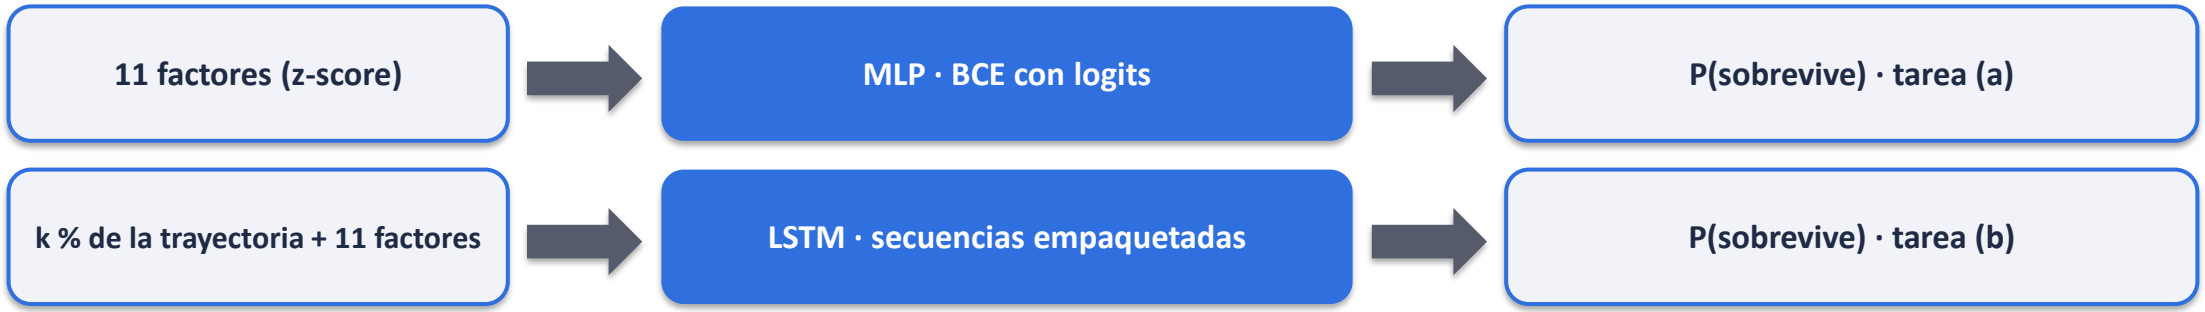
- 50,000 planetas por Latin Hypercube sobre 11 factores; δ y κ log-uniformes. Supervivencia 49.6%.
- Rangos: δ $5\cdot10^{-6}$–$6\cdot10^{-5}$, κ 1–3, s 3.5–$6.5\cdot10^{-4}$, eficiencia hídrica 0–0.6, temperatura 0–5 °C, agua 0.05–1.2, eventos 0–0.12/año (severidad 0.1–0.9), élites 0–10 %.
- Split 70/15/15 por planeta: 35,000 / 7,500 / 7,500. Estáticas: log(δ, κ) + z-score con estadísticas solo de train.
- Secuencia: 101 pasos × 6 canales (log x_C, log x_E, y/100, log w, eventos, tiempo), z-score con train (S12: serie → problema supervisado).
- Monte Carlo: 500 planetas de test × 32 réplicas = 16 000 simulaciones → P(sobrevive | parámetros). En 31% la probabilidad es intermedia.







Modelos: la red tiene que ganarse su lugar



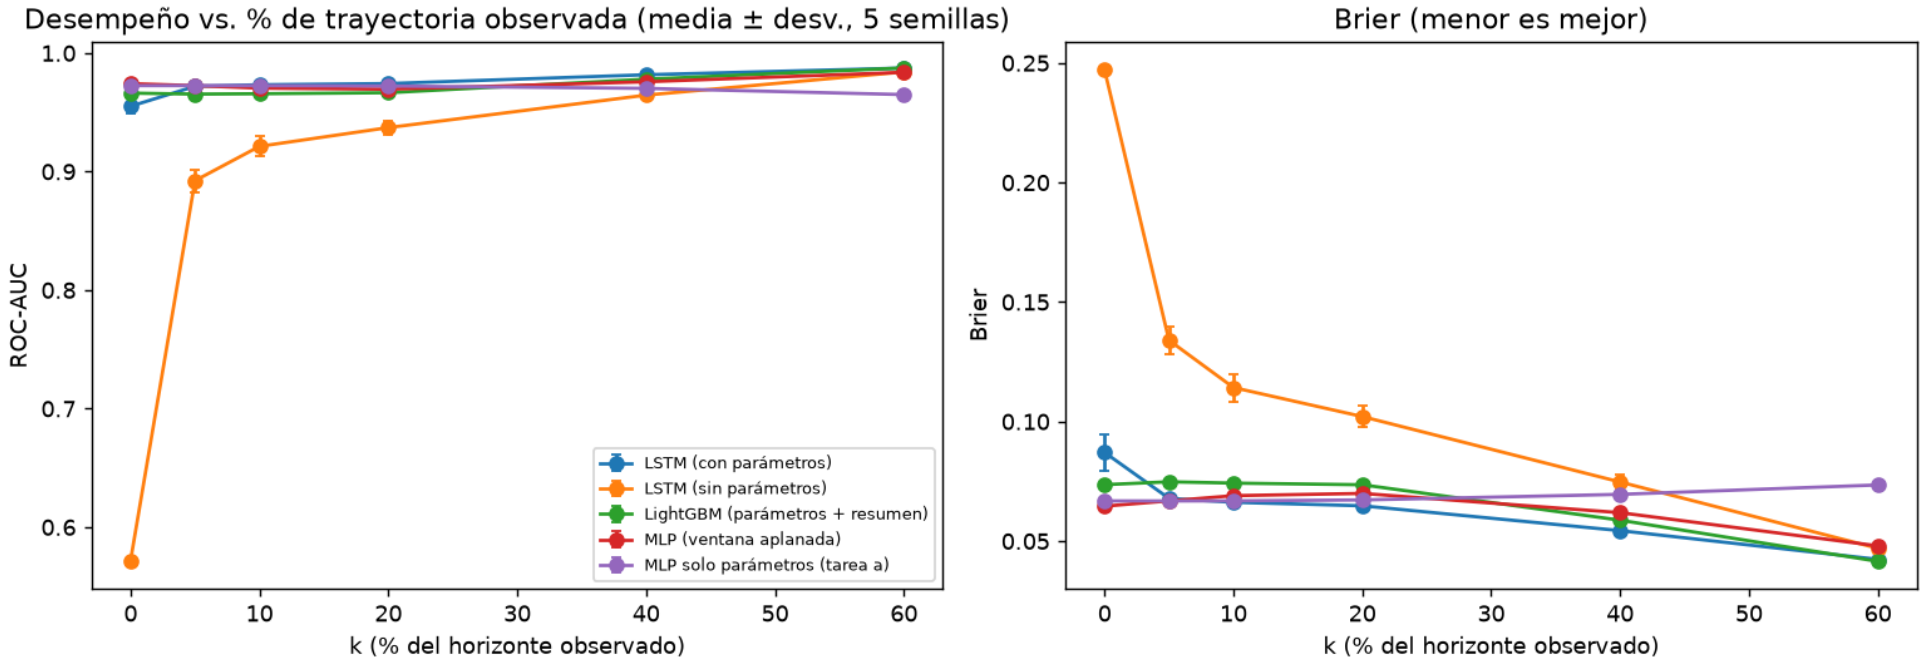
Modelo	Arquitectura	Entrenamiento
MLP (a)	11→128→64→1, ReLU, dropout 0.2 · 9 857 parámetros	AdamW lr 0.003, wd 0.0001; lote 512; paciencia 15
LSTM (b)	2 capas × 128, dropout 0.1; estáticas en cada paso y en la cabeza · 225 409 par.	AdamW lr 0.002, wd 0.01; k aleatorio ∈ [0, 70]; paciencia 12
LightGBM	1 000 árboles, 31 hojas, tasa 0.05 (estáticas, o resúmenes de la ventana)	submuestreo 0.8, columnas 0.9
Otros baselines	Regresión logística · MLP sobre la ventana · MLP solo con parámetros	LSTM sin estáticas (ablación)

- Búsqueda aleatoria de hiperparámetros: MLP 12 configuraciones (capas, dropout, lr, wd), LSTM 8; 5 semillas; IC 95 % por bootstrap pareado (1 000 remuestreos).
- Sin fuga: solo se evalúan planetas aún vivos al final de la ventana; se reporta cuántos quedan fuera.
- Vínculos con el curso: S1 neurona/ReLU · S3 LSTM y compuertas · S8 BCE, AdamW, dropout, early stopping · S12 ventanas.

Resultados de los modelos

Tarea (a)	ROC-AUC	Brier	ECE	MAE vs P verdadera
Regresión logística	0.732 ± 0.000	0.209 ± 0.000	0.018	0.342 ± 0.000
LightGBM	0.966 ± 0.000	0.074 ± 0.001	0.013	0.077 ± 0.001
MLP	0.973 ± 0.001	0.066 ± 0.001	0.010	0.054 ± 0.001

- MLP − LightGBM: ΔAUC +0.0062 [+0.0044, +0.0080] (IC 95 %).
- k = 60 %: LSTM 0.987 vs. LightGBM 0.987 → empatan.
- k = 40 %: LSTM 0.982 vs. MLP estático 0.970.
- Sin parámetros estáticos, la LSTM parte casi del azar (k = 0).



Explicaciones y cómo las verificamos

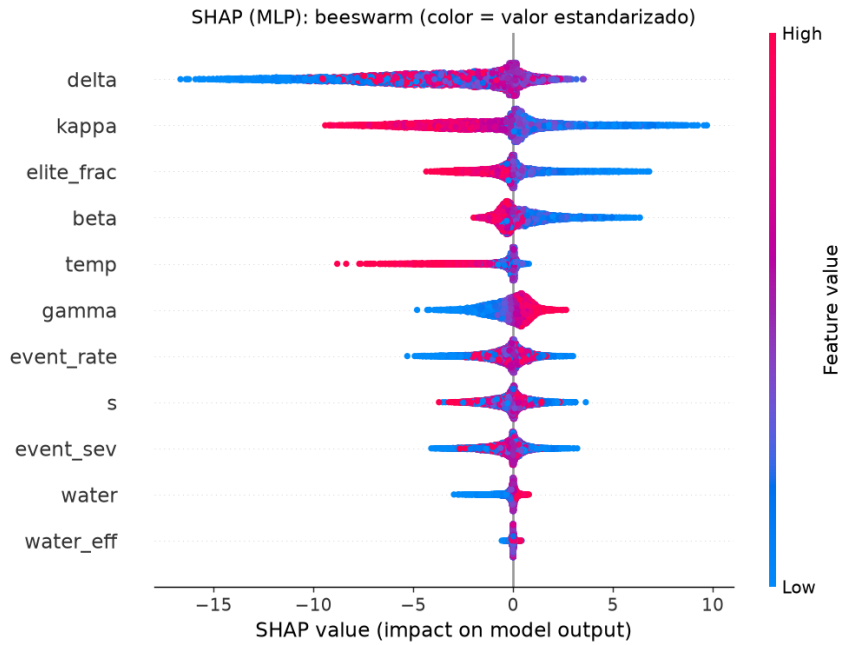
Mismo baseline (planeta medio de entrenamiento = vector 0)
Misma salida (logit de supervivencia)

SHAP exacto · MLP
2^{11} = 2 048 coaliciones
vs. KernelSHAP: ≈ $3 \cdot 10^{-7}$

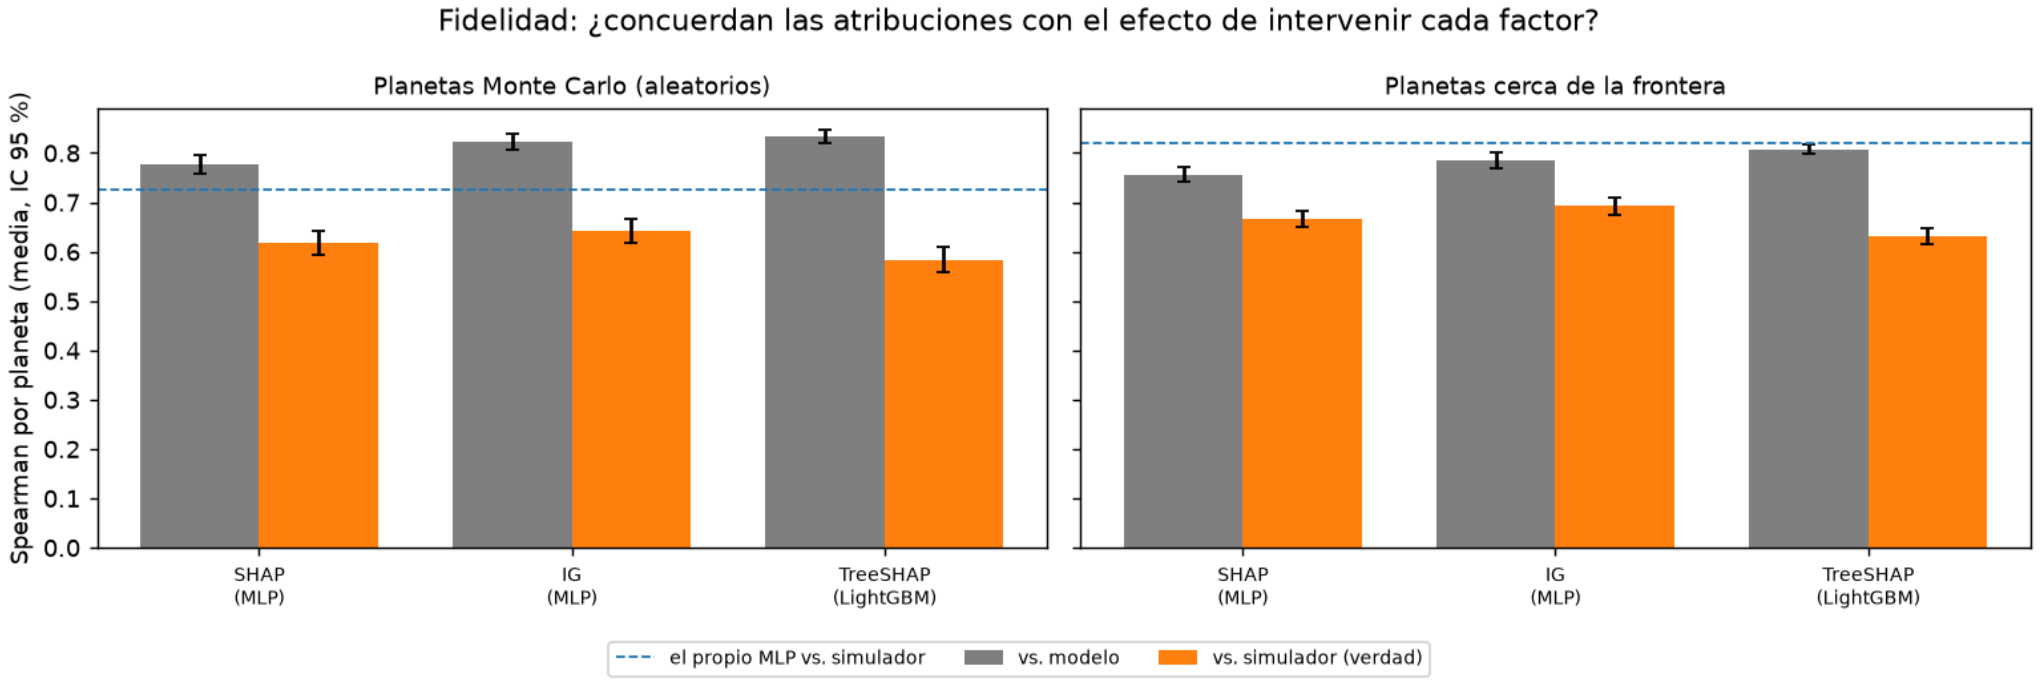
Integrated Gradients · MLP
Captum, 1 024 pasos
error de completitud ≤ 0.03

TreeSHAP · LightGBM
polinomial en el árbol
error ≈ $3 \cdot 10^{-7}$

- Intervención en el modelo: ¿cambia el logit como dice ϕ?
- Intervención en el simulador: 64 réplicas, números aleatorios comunes; efecto real si $|\Delta P| > 0.10$. 980 planetas de frontera + 382 Monte Carlo con efecto.
- Métricas: Spearman por planeta, acuerdo de signo, top-1 y top-3.
- Curvas de eliminación: orden por atribución vs. aleatorio (12 pasos, 32 réplicas).
- Prueba de cordura: pesos aleatorizados (Adebayo et al., 2018).



¿Son fieles las explicaciones? Resultados

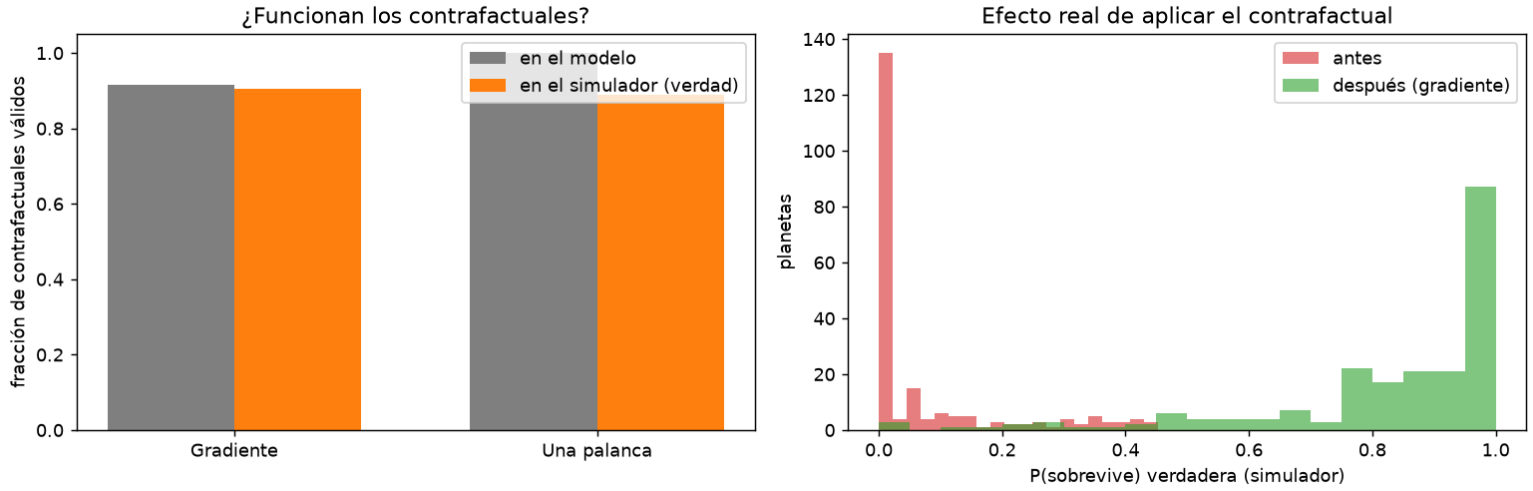


- Spearman vs. simulador: 0.67 (SHAP), 0.69 (IG), 0.63 (TreeSHAP) en planetas de frontera (n = 980); signo correcto ≈91%; factor n.º 1 acertado ≈50%–61%.
- Techo del modelo: el efecto que predice el propio MLP vs. el simulador llega solo a ρ = 0.82.
- Eliminación en el simulador: orden SHAP -0.27 vs. aleatorio +0.17 (cambio medio de P).
- Prueba de cordura: Spearman vs. simulador 0.65 (entrenado) → -0.13 (pesos aleatorios).

Contrafactuales verificados y demo

- Pregunta: ¿cuál es el cambio mínimo en las palancas accionables (δ, κ, s, eficiencia hídrica) que lleva el planeta a sobrevivir?
- Búsqueda: Adam sobre el desplazamiento Δ en espacio estandarizado (600 pasos, lr 0.03), solo en 4 palancas, recortado al rango.
- Pérdida: bisagra hasta P ≥ 0.8 (logit ≈ 1.39) + 0.5 · L1(Δ / rango) → pocas palancas (S8: L1 → dispersión). Verificación: 64 réplicas del simulador.
- Gradiente: 100% resueltos; 90% válidos en el simulador; P real 0.07 → 0.83; 2.0 palancas.
- Una sola palanca (rejilla de 201): 87% resueltos; 89% válidos en el simulador. Los factores no accionables nunca se modifican.

DEMO EN VIVO
streamlit run app/streamlit_app.py



Conclusiones y límites

Lo que encontramos

- ROC-AUC: MLP 0.973 · LightGBM 0.966 · logística 0.732; la ventaja del MLP tiene IC que excluye 0.
- Alerta temprana: con k = 40 %, LSTM 0.982 vs. MLP estático 0.970; con k = 60 % empata con LightGBM.
- Las explicaciones concuerdan con el simulador (ρ ≈ 0.63–0.69) y pasan la prueba de cordura, pero no son una verdad (S15).
- 90% de los contrafactuales funcionan en el simulador.

Límites

- Efecto de un factor a la vez: no captura interacciones.
- Temperatura y agua: supuestos nuestros, sin calibración empírica.
- No igualamos el umbral del Tipo-N del paper (depende del integrador).
- 5 semillas y un solo simulador (datos sintéticos).