Simulador de mundos habitables

Predicción de supervivencia con modelos sustitutos y explicabilidad verificable

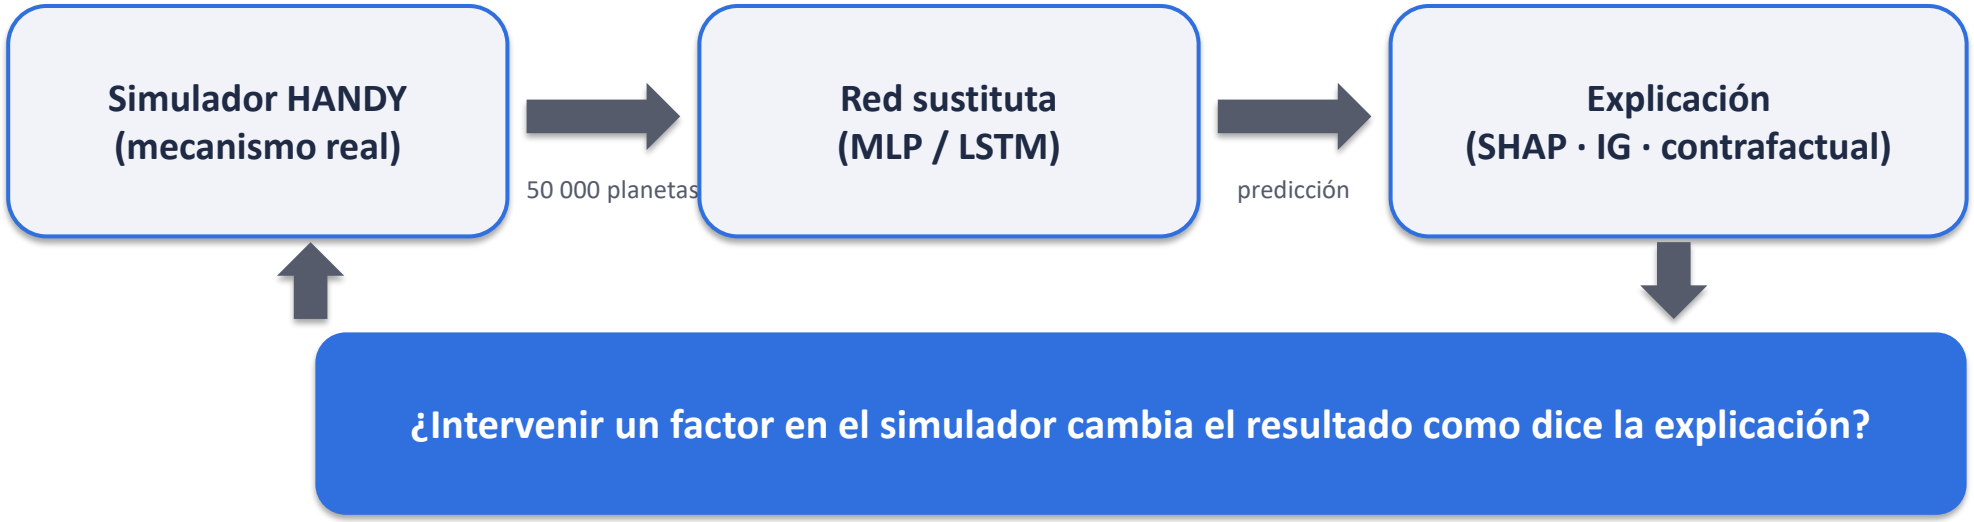
¿Podemos creerle a una explicación?

Gabriel Bran · David Domínguez · Jonathan Díaz

Deep Learning · Sección 10 · Universidad del Valle de Guatemala · 2 de noviembre de 2026

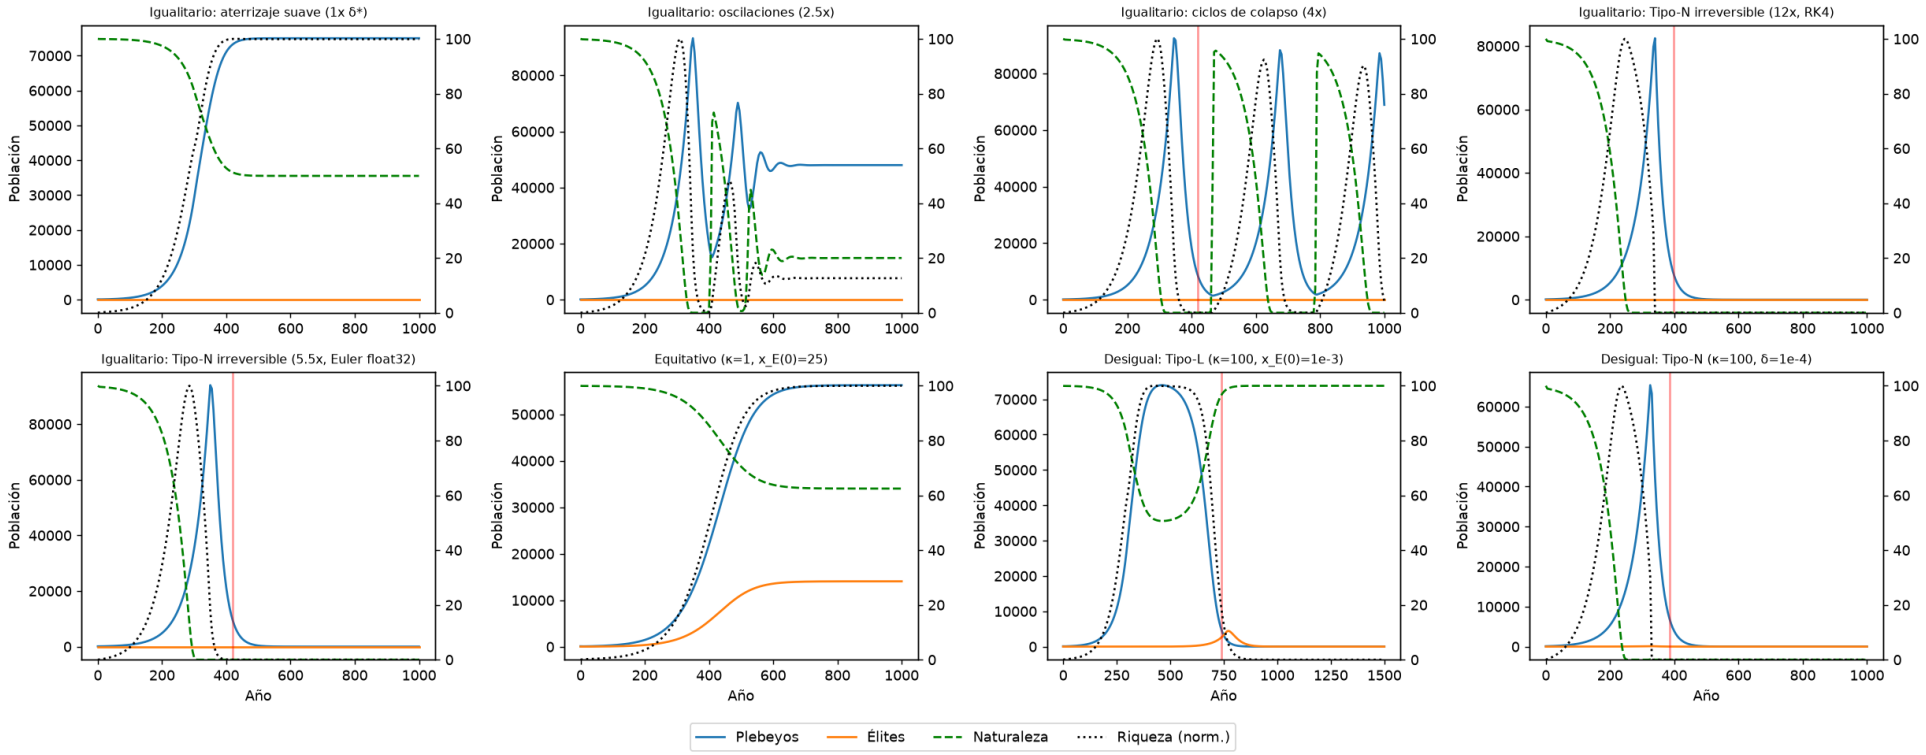
El problema: sustitutos que no sabemos explicar

- Los simuladores científicos son caros: se usan redes como modelos sustitutos (surrogates).
- Las explicaciones (SHAP, IG, contrafactuales) casi nunca tienen una verdad de referencia.
- Aquí sí: el simulador es el mecanismo real, así que podemos intervenir y comprobar.



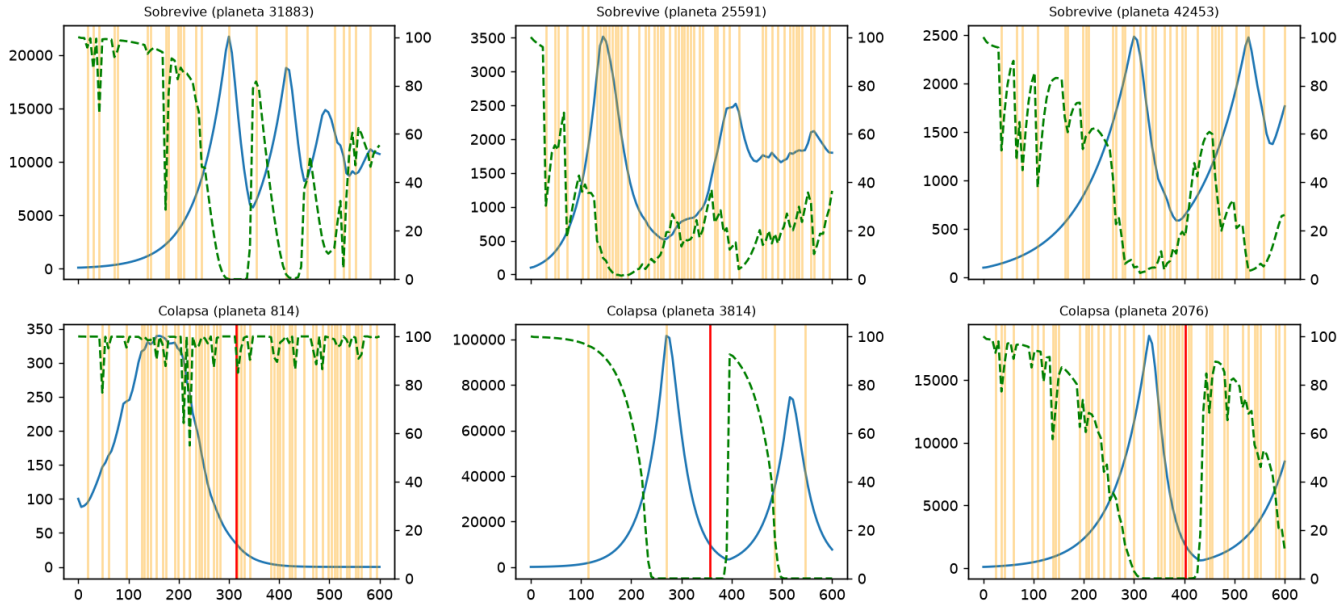
El simulador: HANDY extendido

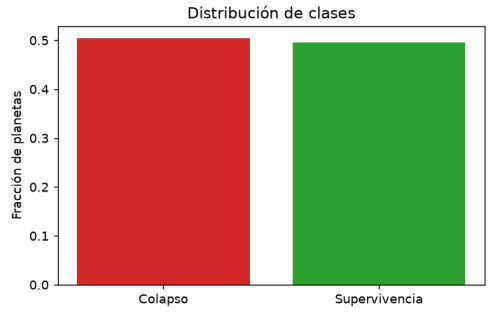
- 4 variables (plebeyos, élites, naturaleza, riqueza); ecuaciones verificadas contra el paper de 2014 (y un error nuestro corregido).
- Extensiones: temperatura, agua y eventos extremos (Poisson) → 11 factores; 4 accionables (δ, κ, s, eficiencia hídrica).
- Colapso = población < 10 % de su pico (o < 20 % de la inicial) antes del año 600.

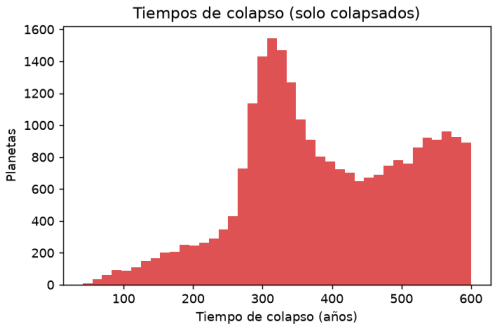


Datos: 50 000 planetas y una verdad de referencia

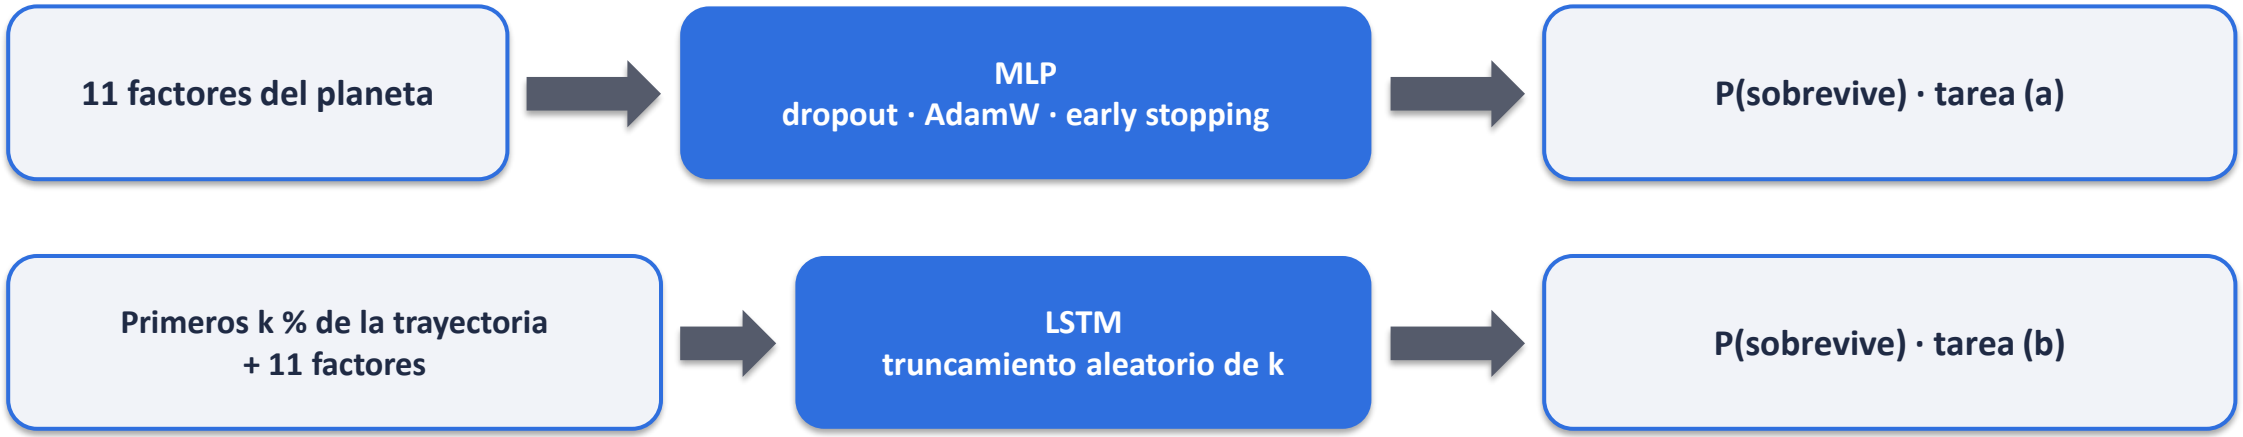
- 50,000 planetas (LHS), 11 factores; supervivencia 49.6%.
- Split 70/15/15 por planeta; normalización solo con train.
- Eventos aleatorios → mismas condiciones, resultados distintos.
- Monte Carlo: 500 planetas de test × 32 réplicas = P(sobrevive | parámetros). En 31% la probabilidad es intermedia.







Modelos: la red tiene que ganarse su lugar

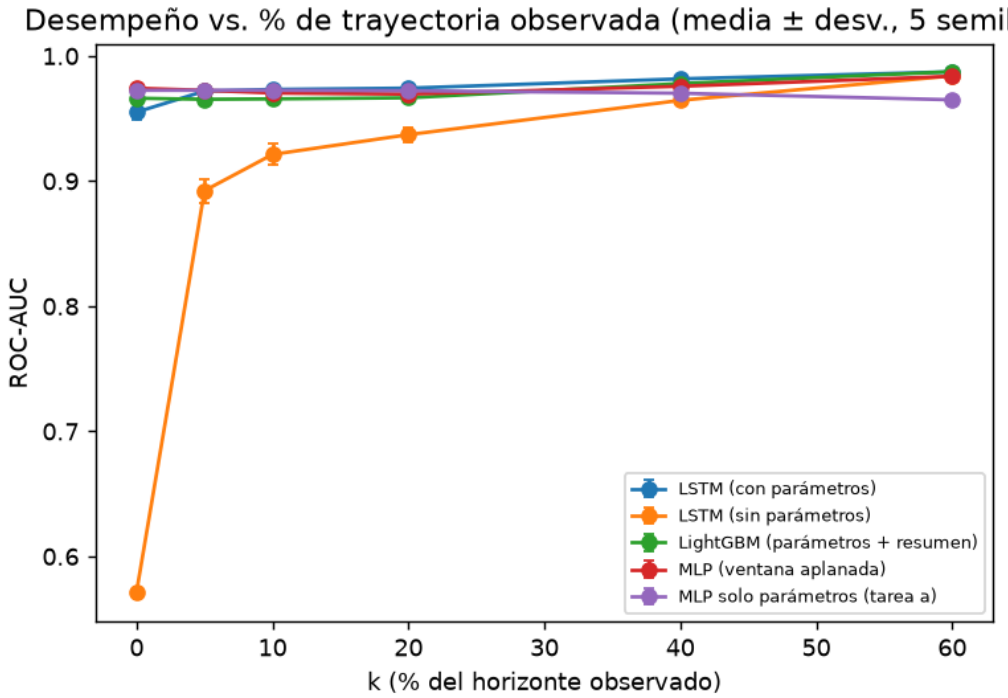


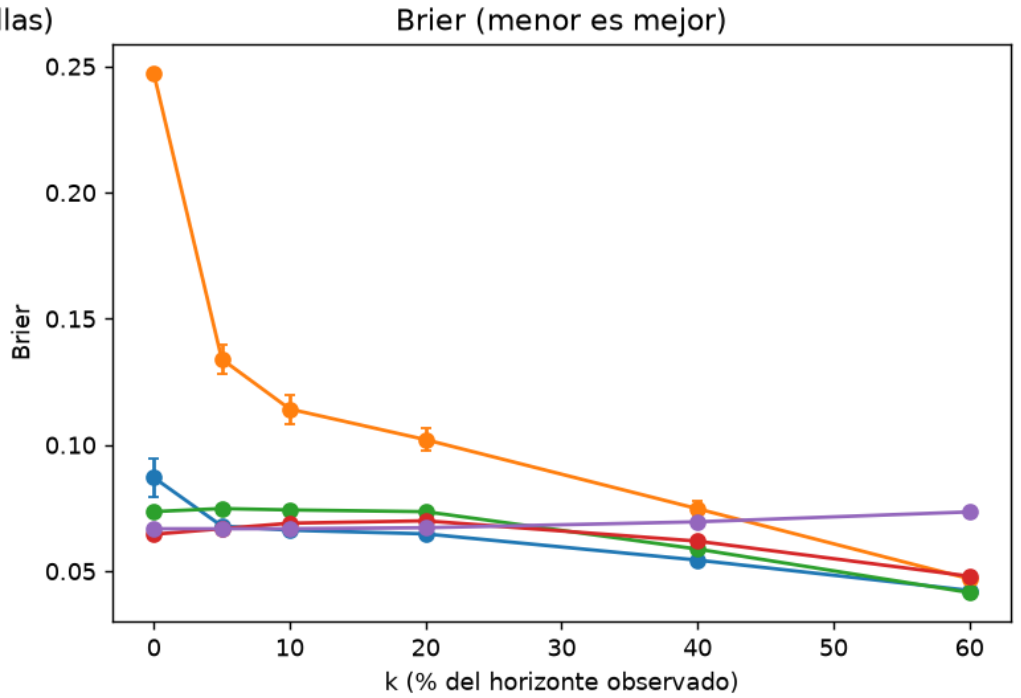
- Baselines obligatorios: regresión logística, LightGBM, MLP sobre la ventana, MLP solo con parámetros.
- Búsqueda de hiperparámetros (MLP: 12 configuraciones; LSTM: 8), 5 semillas, IC 95 % por bootstrap pareado.
- Sin fuga: solo se evalúan planetas aún vivos al final de la ventana; se reporta cuántos quedan fuera.
- Ablación: LSTM con y sin parámetros estáticos.

Resultados de los modelos

Tarea (a)	ROC-AUC	Brier	MAE vs P verdadera
Regresión logística	0.732 ± 0.000	0.209 ± 0.000	0.342 ± 0.000
LightGBM	0.966 ± 0.000	0.074 ± 0.001	0.077 ± 0.001
MLP	0.973 ± 0.001	0.066 ± 0.001	0.054 ± 0.001

- MLP − LightGBM: ΔAUC +0.0062 [+0.0044, +0.0080] (IC 95 %).
- k = 60 %: LSTM 0.987 vs. LightGBM 0.987 → empatan.
- Sin parámetros estáticos, la LSTM parte casi del azar (k = 0).



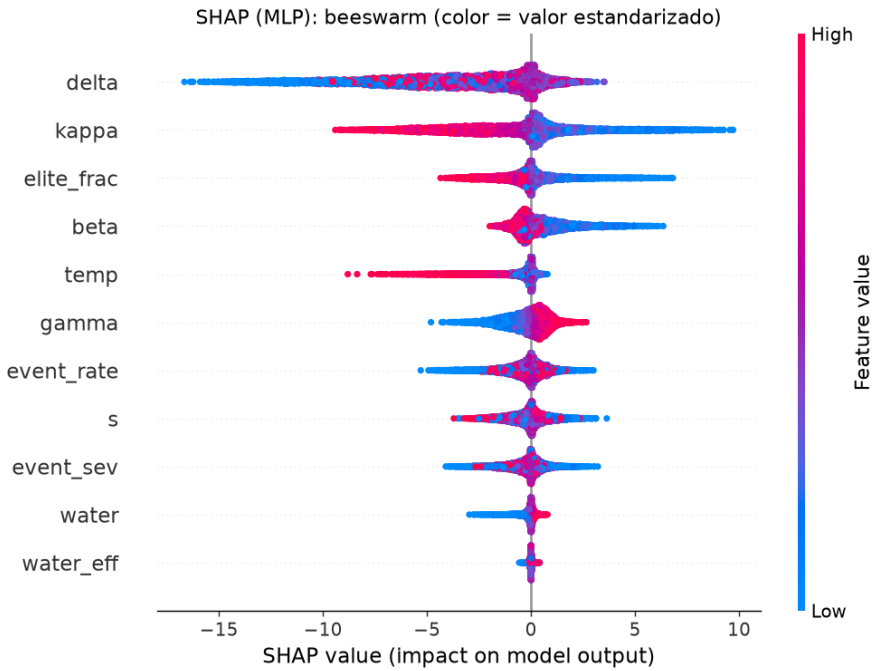


Explicaciones y cómo las verificamos

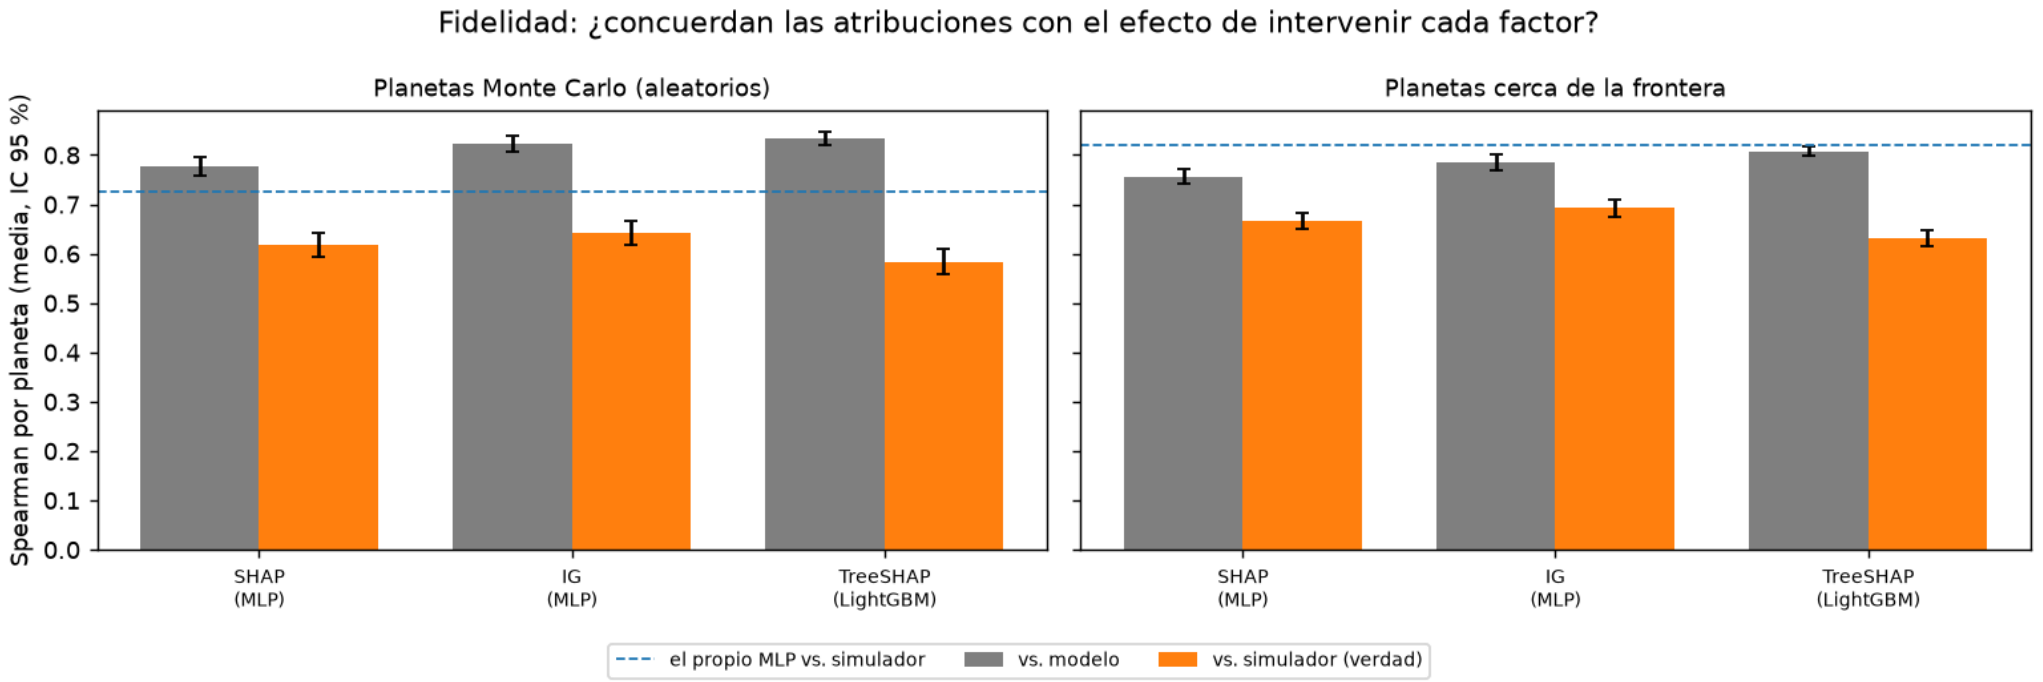
Mismo baseline (planeta medio de entrenamiento)
Misma salida (logit de supervivencia)

SHAP exacto	Integrated Gradients	TreeSHAP
MLP · 2^{11} coaliciones	MLP · Captum	LightGBM

- Intervención en el modelo: ¿cambia el logit como dice ϕ?
- Intervención en el simulador (64 réplicas, números aleatorios comunes): la verdad.
- Curvas de eliminación: orden por atribución vs. aleatorio.
- Prueba de cordura: pesos aleatorizados (Adebayo et al., 2018).



¿Son fieles las explicaciones? Resultados

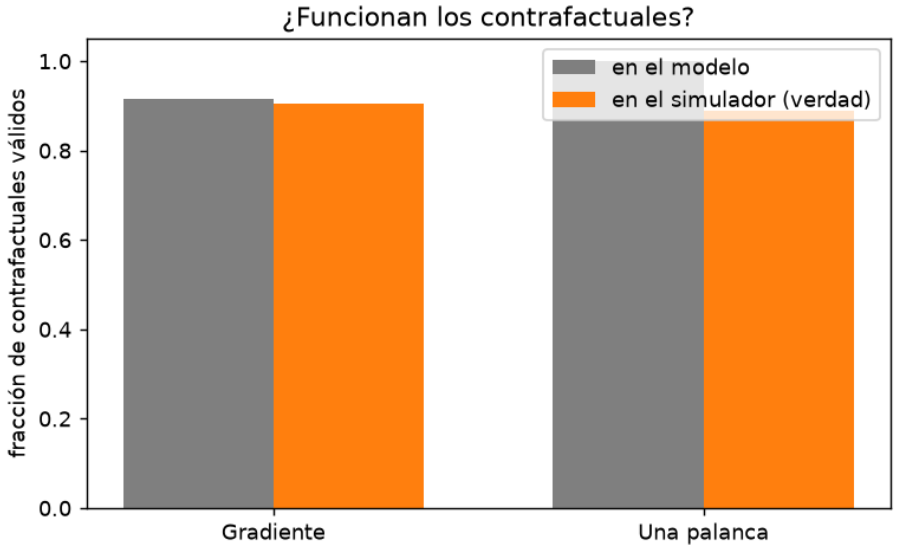


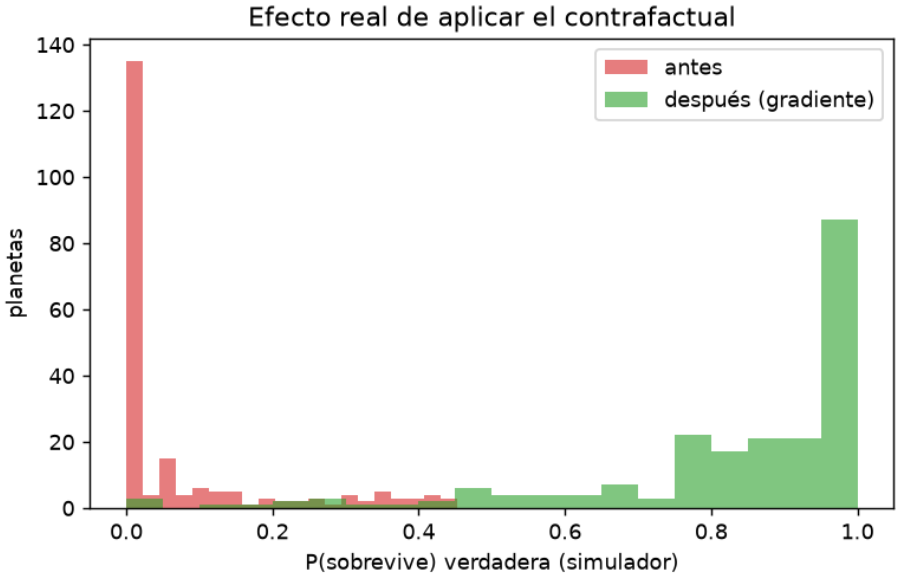
- Spearman vs. simulador: 0.67 (SHAP), 0.69 (IG), 0.63 (TreeSHAP) en planetas de frontera; signo correcto en ≈91%; factor n.º 1 acertado en ≈50%–61%.
- Eliminación en el simulador: orden SHAP -0.27 vs. aleatorio +0.17 (cambio medio de P).
- Prueba de cordura: Spearman vs. simulador 0.65 (modelo entrenado) → -0.13 (pesos aleatorios).

Contrafactuales verificados y demo

- Pregunta: ¿cuál es el cambio mínimo en las palancas accionables (δ, κ, s, eficiencia hídrica) que lleva el planeta a sobrevivir?
- Gradiente: 100% resueltos; 90% válidos en el simulador; P real 0.07 → 0.83.
- Una sola palanca: 87% resueltos; 89% válidos en el simulador.
- Los factores no accionables (temperatura, agua, eventos) nunca se modifican.

DEMO EN VIVO
streamlit run app/streamlit_app.py





Conclusiones y límites

Lo que encontramos

- La red supera a la logística y, por poco pero con IC, a LightGBM.
- La trayectoria ayuda sobre todo con ventanas largas.
- Las explicaciones concuerdan con el simulador ($\rho \approx 0.6–0.7$) y pasan la prueba de cordura.
- 90% de los contrafactuales funcionan en el simulador.

Límites

- Efecto de un factor a la vez: no captura interacciones.
- Temperatura y agua: supuestos nuestros, sin calibración.
- No igualamos el umbral del Tipo-N del paper.
- Modelos con 5 semillas; un solo simulador.